



المدرسة العليا للتكنولوجيا
École Supérieure de Technologie
٢٠٢٥/٢٠٢٦ | ٢٠٢٥/٢٠٢٦ | ٢٠٢٥/٢٠٢٦ | ٢٠٢٥/٢٠٢٦

Rapport : Prédiction de survie des passagers du Titanic

kaggle



Département : Génie Informatique

Filière : Génie Informatique Embarqué

Réaliser par : KADIM Amina

Encadrer par : AZIZI Mostafa

Année Universitaire : 2025/2026

Table des matières

Table de matière.....	1
Liste des figures	2
Introduction.....	3
Partie I : Description du problème	4
Partie II : Comment participer	7
Partie III : Comment gagner	9
Partie IV : Analyse exploratoire des données (EDA).....	12
Partie V : Prétraitement des données	14
Partie VI : Modélisation et résultats.....	16
Partie VII : Soumission	18
Conclusion	20
Bibliographie/Webographie.....	21

Liste de figures

Fig 1 : Page principale de compétition Kaggle.....	3
Fig 2 : Distribution du nombre de survivants vs décédés.....	6
Fig 3 : Téléchargement des fichiers CSV.....	8
Fig 4 : Leaderboard Kaggle ou tableau de performance des modèles.....	11
Fig 5 : Capture de la page soumission Kaggle.....	19
Fig 6 : Capture affichant le score.....	19

Introduction

La compétition *Titanic – Machine Learning from Disaster* est l'une des plus célèbres et populaires sur la plateforme Kaggle, particulièrement recommandée pour les débutants souhaitant se familiariser avec le machine learning supervisé. Elle propose un problème simple à comprendre mais suffisamment riche pour apprendre les concepts fondamentaux de l'analyse de données : à partir des informations relatives aux passagers, telles que le sexe, l'âge, la classe du billet, le nombre de membres de la famille à bord, ou encore le tarif payé, il s'agit de prédire si chaque passager a survécu ou non au tragique naufrage du Titanic. Cette compétition permet aux participants de développer et de renforcer plusieurs compétences clés, notamment le prétraitement des données, la création de nouvelles features, la sélection et l'évaluation de modèles de machine learning, ainsi que la validation des performances via des techniques comme la cross-validation. De plus, elle offre une expérience pratique sur la plateforme Kaggle, où il faut préparer ses prédictions dans le format requis et les soumettre pour évaluation sur le leaderboard, ce qui permet de mesurer ses performances par rapport à d'autres participants dans le monde entier. Pour accéder à cette compétition et commencer à explorer les données.




Fig 1 : Page principale de compétition Kaggle

Partie I :

Description du problème

La compétition est un problème de classification binaire : survie = 0 ou 1.

Variables principales :

Colonne	Description
PassengerId	Identifiant unique du passager
Pclass	Classe du billet (1, 2 ou 3)
Name	Nom du passager
Sex	Sexe du passager
Age	Âge en années
SibSp	Nombre de frères/sœurs/conjoints à bord
Parch	Nombre de parents/enfants à bord
Ticket	Numéro de ticket
Fare	Prix du billet
Cabin	Numéro de cabine
Embarked	Port d'embarquement : C = Cherbourg, Q = Queenstown, S = Southampton

- Variable cible : Survived (0 = décédé, 1 = survécu)
- Problématique : Identifier quelles caractéristiques influencent la survie pour créer un modèle prédictif efficace.

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.925		S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1	C123	S
5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.05		S
6	0	3	Moran, Mr. James	male		0	0	330877	8.4583		Q
7	0	1	McCarthy, Mr. Timothy J	male	54	0	0	17463	51.8625	E46	S
8	0	3	Palsson, Master. Gosta Leonard	male	2	3	1	349909	21.075		S
9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27	0	2	347742	11.1333		S
10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14	1	0	237736	30.0708		C
11	1	3	Sandstrom, Miss. Marguerite Rut	female	4	1	1	PP 9549	16.7	G6	S
12	1	1	Bonnell, Miss. Elizabeth	female	58	0	0	113783	26.55	C103	S
13	0	3	Saunderscock, Mr. William Henry	male	20	0	0	A/5. 2151	8.05		S
14	0	3	Andersson, Mr. Anders Johan	male	39	1	5	347082	31.275		S
15	0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14	0	0	350406	7.8542		S
16	1	2	Hewlett, Mrs. (Mary D Kingcome)	female	55	0	0	248706	16		S
17	0	3	Rice, Master. Eugene	male	2	4	1	382652	29.125		Q
18	1	2	Williams, Mr. Charles Eugene	male		0	0	244373	13		S
19	0	3	Vander Planke, Mrs. Julius (Emelia Maria Vandemoortele)	female	31	1	0	345763	18		S
20	1	3	Masselmani, Mrs. Fatima	female		0	0	2649	7.225		C
21	0	2	Fynney, Mr. Joseph J	male	35	0	0	239865	26		S
22	1	2	Beesley, Mr. Lawrence	male	34	0	0	248698	13	D56	S

Fig 2 : distribution du nombre de survivants vs décédés

Partie II :

Comment participer

Pour participer à la compétition *Titanic – Machine Learning from Disaster*, la première étape consiste à *créer un compte sur la plateforme Kaggle*, ce qui permet d'accéder aux données, de suivre les règles de la compétition et de soumettre ses prédictions. Une fois le compte créé, il faut se rendre sur la page officielle de la compétition Titanic, où l'on *peut télécharger les fichiers essentiels* pour commencer : le fichier *train.csv*, qui contient les données d'entraînement avec la colonne cible Survived, et le fichier *test.csv*, qui contient les passagers pour lesquels il faudra prédire la survie.

Après avoir téléchargé ces fichiers, l'étape suivante consiste à *analyser et nettoyer les données*. Cela inclut la vérification des valeurs manquantes, la compréhension des distributions des variables, la conversion des données catégorielles en valeurs numériques, et la création éventuelle de nouvelles features qui pourraient améliorer la performance du modèle. Cette étape est cruciale, car des données propres et bien préparées augmentent significativement la précision des prédictions.

Une fois les données prêtes, il faut *développer un modèle de machine learning* supervisé capable de prédire la survie des passagers. Différents modèles peuvent être testés, tels que la régression logistique, les arbres de décision, les forêts aléatoires ou les méthodes de gradient boosting comme XGBoost ou LightGBM. Chaque modèle doit être évalué à l'aide de techniques de validation comme la cross-validation pour éviter le surapprentissage et choisir la meilleure approche.

Enfin, lorsque le modèle est entraîné et validé, les prédictions sur le fichier *test.csv* doivent être préparées au format requis par Kaggle, c'est-à-dire un fichier CSV contenant les colonnes PassengerId et Survived. Ce fichier est ensuite *soumis sur la plateforme Kaggle*, où il est évalué automatiquement et comparé aux résultats des autres participants sur le leaderboard. Cette soumission permet de mesurer la performance réelle du modèle et de se situer parmi la communauté internationale de data scientists.




Fig 3 :téléchargement des fichiers CSV

Partie III :

Comment gagner

Pour obtenir un bon score dans la compétition Titanic – Machine Learning from Disaster, il est essentiel de suivre une démarche méthodologique structurée, allant de l'analyse des données jusqu'à l'optimisation du modèle final.

La première étape consiste à réaliser une analyse exploratoire des données (EDA). Cette phase permet de mieux comprendre la structure du dataset et d'identifier les problèmes potentiels. Il est nécessaire de repérer les valeurs manquantes, notamment dans les variables Age, Cabin et Embarked, qui peuvent fortement influencer les performances du modèle si elles ne sont pas correctement traitées. L'EDA inclut également la visualisation des distributions des variables importantes telles que le sexe (Sex), la classe du billet (Pclass) et l'âge (Age). Ces visualisations permettent de mettre en évidence des tendances significatives, par exemple le fait que les femmes et les passagers de première classe ont eu un taux de survie plus élevé. Enfin, l'analyse des corrélations entre les variables explicatives et la variable cible Survived aide à identifier les caractéristiques les plus influentes pour la prédiction.

La deuxième étape est le prétraitement des données, une phase cruciale pour améliorer la qualité du modèle. Elle consiste à remplacer les valeurs manquantes en utilisant des méthodes appropriées, comme la médiane pour la variable Age ou la valeur la plus fréquente pour Embarked. Les variables catégorielles, telles que Sex et Embarked, doivent être converties en valeurs numériques afin d'être interprétables par les algorithmes de machine learning, par exemple à l'aide d'un encodage binaire ou d'un one-hot encoding. De plus, la création de nouvelles features permet d'enrichir le dataset : la variable FamilySize, calculée à partir de SibSp et Parch, permet de représenter la taille de la famille à bord, tandis que la variable IsAlone indique si un passager voyageait seul ou non, ce qui peut avoir un impact sur la survie.

La troisième étape concerne le choix des modèles de machine learning. Plusieurs algorithmes peuvent être testés afin de comparer leurs performances. La régression logistique est souvent utilisée comme modèle de base en raison de sa simplicité et de son interprétabilité. Les arbres de décision permettent de modéliser des relations non linéaires entre les variables. Les forêts aléatoires (Random Forest) améliorent généralement la précision en combinant plusieurs arbres, tandis que les méthodes de gradient boosting, telles que XGBoost ou LightGBM, offrent souvent les meilleures performances grâce à leur capacité à corriger progressivement les erreurs des modèles précédents.

La quatrième étape est l'évaluation des modèles. Afin d'éviter le surapprentissage (overfitting), il est recommandé d'utiliser la cross-

validation, qui permet de tester le modèle sur plusieurs sous-ensembles des données. Les performances sont mesurées à l'aide de métriques adaptées, notamment l'accuracy, qui indique le pourcentage de prédictions correctes, et le F1-score, qui représente un bon compromis entre la précision et le rappel, surtout lorsque les classes ne sont pas parfaitement équilibrées.

Enfin, la dernière étape consiste en l'optimisation du modèle. Cette phase inclut le tuning des hyperparamètres, par exemple le nombre d'arbres dans une Random Forest ou la profondeur maximale d'un arbre de décision. Des techniques comme la recherche par grille (Grid Search) ou la recherche aléatoire (Random Search) peuvent être utilisées pour trouver les meilleurs paramètres. Une fois cette optimisation réalisée, le meilleur modèle est sélectionné en fonction de ses performances globales, puis utilisé pour générer les prédictions finales à soumettre sur Kaggle.




Fig 4 : Leaderboard Kaggle ou tableau de performance des modèles

Partie IV:

Analyse exploratoire des données (EDA)

L'analyse exploratoire des données constitue une étape essentielle afin de mieux comprendre la structure du dataset et d'identifier les éléments susceptibles d'influencer la survie des passagers. La première observation concerne la présence de valeurs manquantes dans plusieurs variables importantes. La variable Age contient un nombre significatif de valeurs nulles, ce qui nécessite un traitement approprié afin d'éviter toute perte d'information. La variable Cabin présente un très grand nombre de valeurs manquantes, ce qui la rend difficile à exploiter directement. Quant à la variable Embarked, elle contient quelques valeurs manquantes pouvant être facilement corrigées.

L'étude des distributions des variables met en évidence plusieurs tendances importantes. L'analyse de la variable Sex montre que les femmes ont un taux de survie nettement supérieur à celui des hommes, ce qui s'explique par la priorité accordée aux femmes et aux enfants lors de l'évacuation. La variable Pclass révèle également une forte influence sur la survie : les passagers de première classe présentent une probabilité de survie beaucoup plus élevée que ceux des deuxième et troisième classes, ce qui peut être lié à leur localisation sur le navire et à un accès plus rapide aux canots de sauvetage. En ce qui concerne l'Age, son influence sur la survie est plus modérée, bien que les enfants aient globalement de meilleures chances de survie. Enfin, l'analyse de la variable Fare montre que plus le tarif payé est élevé, plus la probabilité de survie augmente, ce qui est cohérent avec l'effet de la classe sociale.

Afin de visualiser ces relations, plusieurs graphiques ont été utilisés, notamment un histogramme représentant l'âge en fonction de la survie, un diagramme en barres comparant la survie selon le sexe, ainsi qu'un diagramme en barres illustrant la relation entre la classe du billet (Pclass) et la survie. Ces visualisations permettent de confirmer visuellement les tendances observées dans les données.

Partie V :

Prétraitement des données

Après l'analyse exploratoire, une phase de prétraitement des données a été réalisée afin de rendre le dataset exploitable par les algorithmes de machine learning. Les valeurs manquantes ont d'abord été traitées : la variable Age a été complétée en utilisant la médiane, une méthode robuste face aux valeurs extrêmes, tandis que les valeurs manquantes de Embarked ont été remplacées par la valeur la plus fréquente (mode). La variable Cabin, en raison du nombre très élevé de valeurs manquantes, a été soit supprimée, soit utilisée uniquement pour extraire des informations partielles telles que le type de cabine.

Les variables catégorielles ont ensuite été transformées en variables numériques afin de pouvoir être interprétées par les modèles de machine learning. La variable Sex a été encodée de manière binaire, avec la valeur 0 pour les hommes et 1 pour les femmes. La variable Embarked a été convertie à l'aide d'un One-Hot Encoding, générant des colonnes distinctes pour les ports d'embarquement C, Q et S.

Enfin, de nouvelles features ont été créées pour enrichir le dataset et améliorer la capacité prédictive du modèle. La variable FamilySize a été calculée comme la somme de SibSp et Parch, à laquelle on ajoute 1 pour inclure le passager lui-même. Cette variable permet de représenter la taille de la famille à bord. Une autre variable, IsAlone, a été définie afin d'indiquer si un passager voyageait seul (valeur 1) ou accompagné (valeur 0). Ces nouvelles caractéristiques ont permis de capturer des comportements sociaux susceptibles d'influencer la probabilité de survie.

Partie VI :

Modélisation et résultats

Après le prétraitement des données, plusieurs modèles de machine learning ont été testés afin de prédire la survie des passagers du Titanic.

La régression logistique (Logistic Regression) a été utilisée comme modèle de base. Ce modèle simple et interprétable a permis d'obtenir une accuracy de validation satisfaisante, servant de référence pour comparer les autres modèles.

Ensuite, des modèles plus avancés ont été explorés afin d'améliorer les performances. Après entraînement et évaluation, le modèle retenu a permis d'obtenir une accuracy finale de 0.777 sur Kaggle, ce qui représente un résultat correct et cohérent pour cette compétition, notamment pour une première participation.

L'analyse des résultats montre que certaines variables ont une influence importante sur la prédiction de la survie, notamment le sexe du passager (Sex), la classe du billet (Pclass), l'âge (Age), le tarif payé (Fare) ainsi que la taille de la famille (FamilySize). Ces observations confirment les tendances identifiées lors de l'analyse exploratoire des données.

Partie VII :

Soumission

Après l'entraînement du modèle, les prédictions ont été générées à partir du fichier test.csv. Les résultats ont été enregistrés dans un fichier CSV respectant le format exigé par Kaggle, contenant les colonnes PassengerId et Survived.

Exemple du format du fichier de soumission :

PassengerId, Survived


892,0

893,1

894,0


...

Ce fichier a été soumis sur la plateforme Kaggle via la page officielle de la compétition Titanic – Machine Learning from Disaster. Après évaluation automatique, la soumission a obtenu un score final de 0.777 en accuracy, confirmant le bon fonctionnement du modèle et la validité du processus de prétraitement et de modélisation.



The screenshot shows the 'Submit to Competition' interface on Kaggle. It includes tabs for 'File Upload' and 'Notebook'. Under the 'Notebook' tab, there's a section for 'Titanic - Machine Learning from Disaster' with a note about 7 remaining submissions. Below this are four dropdown menus: 'SELECT NOTEBOOK' (selected: notebookd24cace8e0), 'NOTEBOOK VERSION' (selected: Version 1), 'OUTPUT FILE' (selected: submission.csv), and 'SUBMISSION DESCRIPTION' (placeholder: Enter a description). At the bottom right are 'Cancel' and 'Submit' buttons.

Fig 5 : Capture de la page soumission Kaggle



The screenshot shows a notification box from Kaggle. At the top, it displays the user's ID (5360), name (KADIM AMINA), profile picture, current score (0.77751), number of submissions (4), and time since last submission (6h). Below this, a 'Your Best Entry!' message is shown with a trophy icon, stating: 'Your most recent submission scored 0.77751, which is an improvement over your previous score of 0.76555. Great job!'. A 'Tweet this' button is located on the right.

Fig 6 : Capture affichant le score

conclusion

À travers la participation à la compétition Titanic – Machine Learning from Disaster sur Kaggle, ce travail a permis de mettre en pratique les différentes étapes essentielles d'un projet de machine learning supervisé, allant de l'analyse exploratoire des données jusqu'à la soumission finale des prédictions. L'étude du dataset a mis en évidence l'importance du prétraitement des données, notamment la gestion des valeurs manquantes, la transformation des variables catégorielles et la création de nouvelles features pertinentes telles que FamilySize et IsAlone.

Plusieurs modèles ont été explorés afin d'identifier l'approche la plus adaptée pour ce problème de classification. Le modèle retenu a permis d'obtenir un score final de 0.777 en accuracy sur Kaggle, ce qui représente un résultat satisfaisant et cohérent pour une première participation à cette compétition. Ce score confirme que les choix effectués lors du prétraitement et de la modélisation ont permis de capturer les relations essentielles entre les caractéristiques des passagers et leur probabilité de survie.

L'analyse des résultats a également montré que certaines variables jouent un rôle déterminant dans la prédiction de la survie, notamment le sexe, la classe du billet, l'âge, le tarif payé et la taille de la famille. Ces observations sont en accord avec les conclusions issues de l'analyse exploratoire des données et renforcent la pertinence du modèle développé.

En perspective, ce travail pourrait être amélioré par l'utilisation de modèles plus avancés, une optimisation plus poussée des hyperparamètres, ainsi que par l'intégration de nouvelles features issues d'informations supplémentaires, comme les titres extraits des noms des passagers. Cette compétition a ainsi constitué une expérience formatrice, permettant de consolider les bases du machine learning et de se familiariser avec la plateforme Kaggle et ses mécanismes d'évaluation.

Bibliographie

Kaggle. Titanic – Machine Learning from Disaster.

Disponible sur : <https://www.kaggle.com/competitions/titanic>

Kaggle Learn. Machine Learning Courses.

Disponible sur : <https://www.kaggle.com/learn>

Géron, A. (2019). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow.

O'Reilly Media.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python.

Journal of Machine Learning Research, 12, 2825–2830.

Brownlee, J. (2016). Machine Learning Mastery With Python.

Machine Learning Mastery.

Kaggle Notebook – Titanic Tutorial.

Disponible sur : <https://www.kaggle.com/code>

Bishop, C. M. (2006). Pattern Recognition and Machine Learning.

Springer.